# Méthodologie

*Recherche de l'origine du nom de famille.*

← Retour à la recherche

## Le problème

Les noms de famille français sont le fruit de siècles d'évolution : un même nom ancestral a engendré des dizaines de formes locales, dialectales et orthographiques. *Lefebvre*, *Lefebre*, *Lefaivre* ou *Le Febvre* désignent la même origine — le forgeron — mais n'ont jamais été unifiés. La base contient 21 777 entrées ; le défi est de relier chaque variante à sa **racine commune** pour en restituer la signification.

ORTHOGRAPHIQUE
Lefebre → **Lefebvre**

PARTICULE
Le Febre → **Lefebvre**

FAUTE DE FRAPPE
Dupond → **Dupont**

PHONÉTIQUE FR
Lefaivre → **Lefebvre**

DOUBLEMENT
Pottier → **Potier**

RÉGIONALE
Bideaud → **Bideault**

## Les données

| SOURCE | CONTENU | VOLUME |
|---|---|---|
| names.json | Noms de famille → IDs d'origines | 21 777 entrées |
| origins.json | Textes étymologiques détaillés (FR) | 20 981 textes |
| prenoms.json | Prénoms → IDs d'origines | 1 769 entrées |
| origins_prenoms_fr.json | Textes d'origines traduits EN→FR via Google Translate | 1 769 textes |
| prenoms_insee.json | Fréquence des prénoms (INSEE nat2021) | 34 176 prénoms |

| SOURCE | CONTENU | VOLUME |
|---|---|---|
| noms_insee.json | Fréquence des noms de famille (INSEE 2008) | 218 982 noms |

*La couverture est partielle : les noms absents de la base sont la norme, pas l'exception. Certains noms très courants (Dubois, Fontaine) n'y figurent pas sous leur forme canonique.*

## Normalisation

Étape préalable à toute comparaison — souvent sous-estimée mais décisive :

1. **Minuscule + NFD** — suppression des accents (é→e, ç→c)
2. **Tirets et apostrophes** → espaces unifiés
3. **Agglutination des particules** — le/du/de/la/des supprimés en tête
4. **Fusion** — les tokens restants sont concaténés sans espace

Le Febvre → le febvre → le febvre → **febvre**

*Sans cette étape, "Le Febvre" ne matche jamais "lefebvre" dans la base.*

## Méthodes testées

RETENU

### Levenshtein

Distance d'édition minimale entre deux chaînes (insertions, suppressions, substitutions). Efficace sur les fautes de frappe et substitutions de caractères.

RETENU

### TF-IDF

Vectorisation par bigrammes et trigrammes de caractères. Capture les séquences communes entre variantes orthographiques. Rapide (3 ms/requête).

PIPELINE FINAL

### Hybride Lev + TF-IDF

Fusion par rang : chaque méthode donne des points par proposition. La proposition avec le plus de points est retenue.

ÉLIMINÉE

### Double Metaphone

Algorithme phonétique conçu pour l'anglais. Performance

ÉLIMINÉE

### LLM seul

Hallucinations sur les noms rares. Non ancré dans les données. Peut inventer une

insuffisante sur les noms français rares.

étymologie plausible mais fausse.

## Benchmarks

### BENCHMARK — 300 CAS TESTÉS

50 noms au hasard dans la base et on leur a appliqué 6 types de fautes (inversion, doublement, suppression…). Pour chaque variante, on regarde si la bonne réponse apparaît dans les 5 résultats affichés.

*On part de « Dupont » (qui existe dans la base) → on génère « Dupond » (substitution t→d) → la bonne réponse = retrouver « Dupont », le nom de départ.*

| MÉTHODE | TROUVE DANS LES 5 PREMIERS |
|---|---|
| Lookup exact | 16,7 % |
| Levenshtein | 91,0 % |
| TF-IDF n-grammes | 87,0 % |
| Double Metaphone | 76,7 % |
| **Hybride (retenu)** | **93,7 %** |

### RÉSULTATS PAR TYPE DE PERTURBATION (TF-IDF+LEVENSHTEIN)

*L'inversion de caractères adjacents reste le cas le plus difficile pour toutes les méthodes.*

## Pipeline final

1 **Normalisation**

Minuscule, sans accents, agglutination des particules

↓

2 **Lookup exact**

Correspondance directe dans la base normalisée — score 1,0

↓ si aucun résultat

3 **TF-IDF char n-grammes (2,3)**

Top-5 candidats par similarité cosinus

4 **Levenshtein**

Top-5 candidats par distance d'édition minimale

↓ fusion

5 **Fusion par rang**

Proposition avec le plus haut score

↓

6 **Résumé Mistral**

Le texte d'origine est synthétisé et homogénéisé par un LLM

## Enrichissements

### Famille linguistique

Détection par règles regex sur le texte d'origine (latin, germanique, breton, basque…)

### Variantes orthographiques

Extraction par regex des sections "Variantes :", "Formes voisines :" dans les textes

### Résolution de renvois

"Forme française d'Alfonso" → récupère la définition complète d'Alfonso (1 niveau)

### Popularité INSEE

Rang et nombre de porteurs, sur 34 176 prénoms et 218 982 noms de famille

### Résumé Mistral

Synthèse fluide du texte brut via mistral-small-latest · appel async en parallèle

## Limites

- Le benchmark aléatoire simule des perturbations — il ne reflète pas exactement les saisies réelles des utilisateurs.
- Les variations morphologiques historiques (*Morot* → *Moreau*) ne sont pas gérées : aucune méthode n'y arrive sans connaissance linguistique externe.
- L'inversion de deux caractères adjacents reste le cas le plus difficile.
- La couverture des prénoms est limitée (1 769) comparée aux noms de famille (21 777).
- Le résumé Mistral ajoute ~1–2 s de latence par requête.

---

← Retour à la recherche